腦電訊號分類：EEGNet 與 DeepConvNet

學號：315553010 姓名：楊敦傑
實驗日期：2026/10/19

提交前待補：GitHub 連結。此版本已包含實測結果，尚未完成提交資訊。

1. Introduction

本作業使用課程提供的 BCI Competition III IIIb 預處理資料，根據兩個 EEG 通道的 750 個取樣點進行二元分類。原始標籤 1、2 轉為 0、1；模型直接從訊號學習時間與空間特徵，不另外手工擷取頻帶特徵。

EEGNet 是為 EEG 設計的精簡卷積網路 [1]。先以時間卷積學習訊號變化，再以 depthwise 空間卷積學習不同時間特徵下的通道組合，最後以 separable 卷積整合時間與特徵圖資訊。這種分解方式能降低參數數量，適合有限樣本的 EEG 分類。

本次重點是自行實作模型，固定比較 activation、ELU alpha 與 dropout，並以 DeepConvNet 觀察較大網路的結果。測試準確率不是唯一判斷依據；報告同時檢視 loss、訓練與驗證差距、選模方式與模型規模。

資料	原始筆數	本次用途
S4b_train + X11b_train	540 + 540	訓練 864 / 驗證 216
S4b_test + X11b_test	540 + 540	測試 1080
每個檔案的類別分布	270 / 270	兩類平衡

八組皆完成 150 輪。依驗證指標選定的設定為 eegnet_relu，其 test accuracy 為 85.28%。全部逐輪紀錄的 test 峰值為 85.28%；兩者使用不同的定義，後文分別列示。

2. Experiment setups and result

2.1 EEGNet 實作

階段	運算	輸出形狀（不含 batch）
輸入	兩通道 EEG	1 × 2 × 750
時間特徵	Conv 1→16, (1,51), padding (0,25); BN	16 × 2 × 750
空間特徵	Conv 16→32, (2,1), groups=16; BN; activation	32 × 1 × 750
下採樣	AvgPool (1,4); Dropout	32 × 1 × 187
時間與特徵混合	Depthwise (1,15), groups=32; Pointwise (1,1); BN; activation	32 × 1 × 187
下採樣	AvgPool (1,8); Dropout	32 × 1 × 23
分類	Flatten 736; Linear 736→2	2 logits

EEGNet 可訓練參數共 4,018 個。所有 EEGNet 設定使用相同結構，只變動指定的 activation、alpha 或 dropout。卷積搭配 BN 時移除卷積 bias；分類層保留 bias。

第 7、8 頁投影片作為參考。本次後段明確使用 depthwise 加 pointwise，並非將一般 Conv2d 命名成 separableConv。因此不能將本次數值視為逐層重現投影片普通卷積版本的結果。

CrossEntropyLoss 直接接收兩個 logits；不加入 softmax。預測使用 argmax。測試時使用 eval 模式與停用梯度，確保 dropout 關閉且 BN 使用累積統計。

2.2 實驗設定與公平比較

執行環境：Python 3.12.14、PyTorch 2.9.1+cu126、CUDA 12.6、NumPy 2.2.6、Matplotlib 3.10.8；GPU：NVIDIA GeForce RTX 4070。

以 seed 42，針對 S4b／X11b 各自的兩個類別分層；每個受試者、類別各取 216 筆訓練、54 筆驗證。八組使用完全相同的索引。測試資料不參與梯度更新或 validation checkpoint 選擇。

NaN 補值僅以 864 筆訓練子集估計，全域平均值為 -0.02532666；同一數值套用於三個 split。不額外正規化或增強。每個原始檔案的 SHA-256、切分索引與環境資訊均已保存。

共同設定：150 epochs、batch size 64、Adam、learning rate 0.01、weight decay 0.001、CrossEntropyLoss。固定種子並啟用 deterministic 運算；每組重新初始化模型與 optimizer，不使用 early stopping。

編號	模型／變因	Activation	alpha	Dropout
E1	EEGNet baseline	elu	1.0	0.25
E2	ReLU	relu	-	0.25
E3	LeakyReLU	leakyrelu	-	0.25
E4	ELU alpha=0.5	elu	0.5	0.25
E5	ELU alpha=2	elu	2.0	0.25
E6	Dropout=0	elu	1.0	0.0
E7	Dropout=0.5	elu	1.0	0.5
E8	DeepConvNet	elu	1.0	0.5

每輪保存 train／validation／test 的 loss 與 accuracy。loss 為每個 batch 的平均 loss 乘上該 batch 樣本數後相加，再除以總樣本數，避免最後一個較小 batch 改變權重。Accuracy 為正確筆數除以樣本數。

checkpoint 按 validation accuracy 高者優先，同分選 validation loss 較低者，再同分選較早輪次。七組設定在執行前已固定；test 曲線為作業要求的觀察紀錄，不用來追加調參。

2.3 八組實測結果

設定	選定輪次	Val (%)	選定 Test (%)	Test 峰值 (%)
E1 EEGNet baseline	128	80.09	74.63	76.57
E2 ReLU	139	89.81	85.28	85.28
E3 LeakyReLU	117	87.96	82.87	85.28
E4 ELU alpha=0.5	138	87.04	83.80	83.80
E5 ELU alpha=2	101	75.00	70.83	73.24
E6 Dropout=0	139	75.46	69.44	73.89
E7 Dropout=0.5	121	77.31	73.06	74.63
E8 DeepConvNet	114	81.94	77.59	79.17

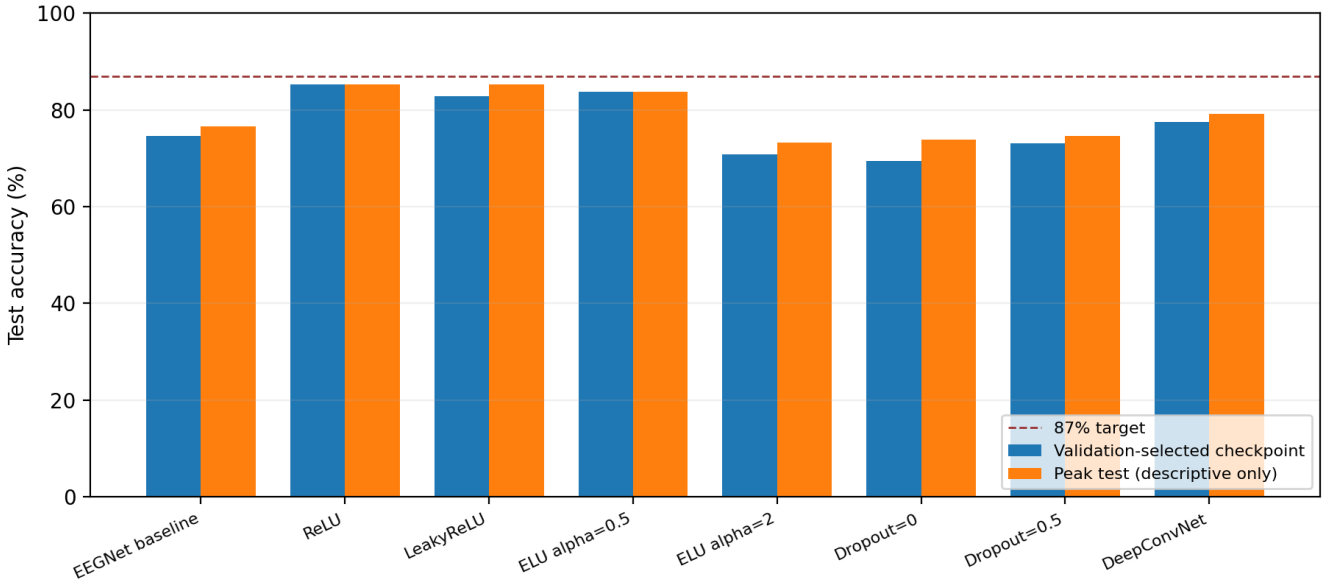


圖 1：驗證集選定權重的 test accuracy，與逐輪 test accuracy 峰值。紅色虛線為 87% 目標。

依 validation 選定的設定為 eegnet_relu，epoch 139，validation accuracy 89.81%，test accuracy 85.28%。此選擇並非按照最高 test accuracy 排序。

逐輪 test 峰值包含跨 epoch 多次觀察的樂觀偏差，不等同獨立且未經觀察的泛化估計。所有欄位直接由 summary.json 與 history.csv 計算，報告產生前會核對一致性。

本次最高 test accuracy 為 85.28%，尚未達到 87% 目標；不將 validation 的較高數字當成 test 結果。

2.4 最高測試準確率與證據

逐輪最高 test accuracy：85.2778%，出現在 eegnet_relu 的 epoch 137。該設定依 validation 選定的是 epoch 139，其 test accuracy 為 85.2778%。

並列最高的設定：eegnet_relu、eegnet_leakyrelu。截圖的原始 CSV 欄位選取其中一組代表輪次。



圖 2：實際瀏覽器結果頁截圖。內容直接讀取實驗 CSV／JSON，保留最高輪次原始欄位；不是終端機畫面。

可使用 README 的 --evaluate 指令重新載入 best.pt。程式會核對原始資料 SHA-256，使用保存的訓練平均值補入 NaN，再以相同 batch size 評估。所有八組 checkpoint 在訓練結束時均會重新載入並與選定輪次的紀錄比較。

若需重現 test 峰值當下的未選定權重，須重新執行固定種子的訓練；本次僅保存 validation 選定權重，避免將 test 峰值當成選模依據。原始峰值紀錄仍可在 history.csv 與 train.log 查驗。

2.5 訓練曲線：E1 與 E2

E1 / EEGNet baseline

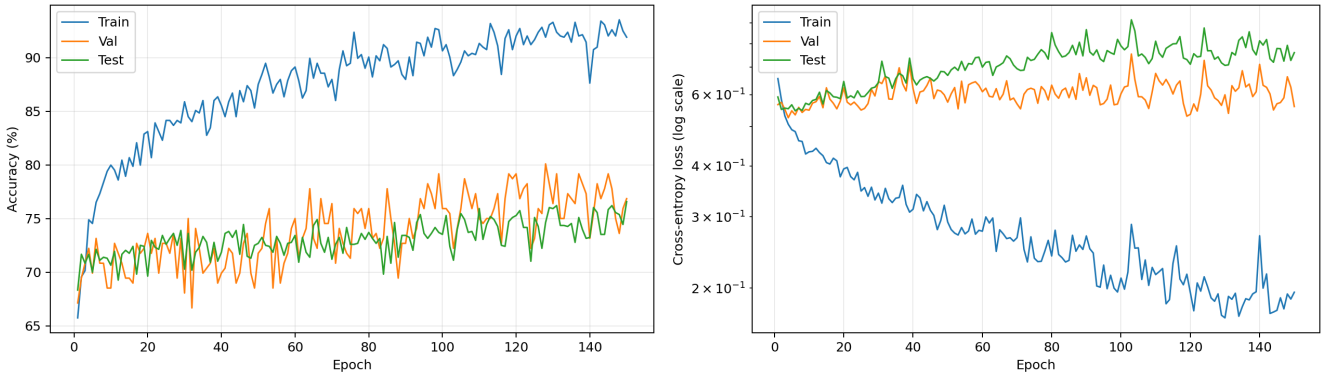


圖 3：左為 accuracy，右為 loss（對數軸）；Train／Val／Test 各 150 輪。

選定 epoch 128：train 91.90%、validation 80.09%、test 74.63%；選定 test loss 0.7431。最後一輪 train／validation accuracy 為 91.90%／76.85%。

E2 / ReLU

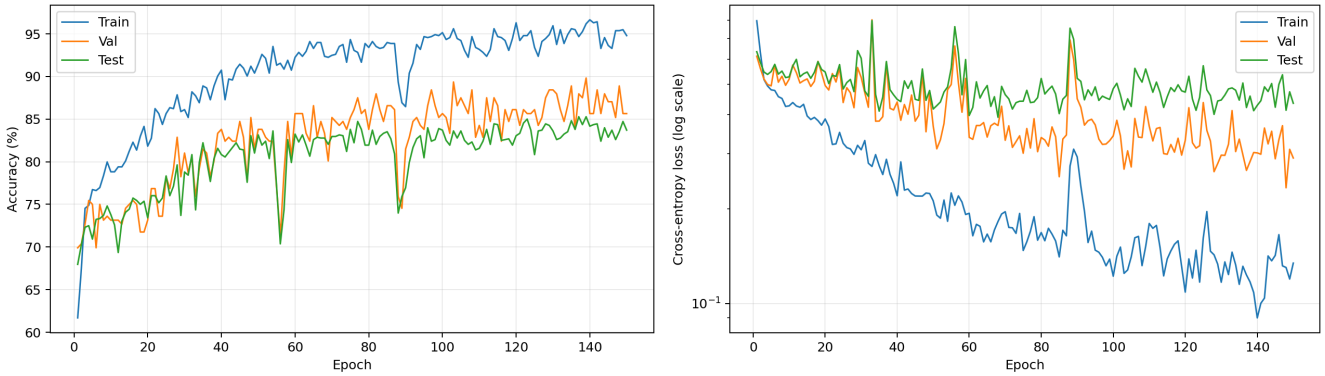


圖 4：左為 accuracy，右為 loss（對數軸）；Train／Val／Test 各 150 輪。

選定 epoch 139：train 96.18%、validation 89.81%、test 85.28%；選定 test loss 0.4114。最後一輪 train／validation accuracy 為 94.79%／85.65%。

Train 指標在 dropout 開啟且權重持續更新時累計；Val／Test 在每輪更新後以 eval 模式計算。曲線高度不能單憑 train 與 test 的大小判定資料洩漏或過擬合，應配合 validation loss 變化解讀。

2.6 訓練曲線：E3 與 E4

E3 / LeakyReLU

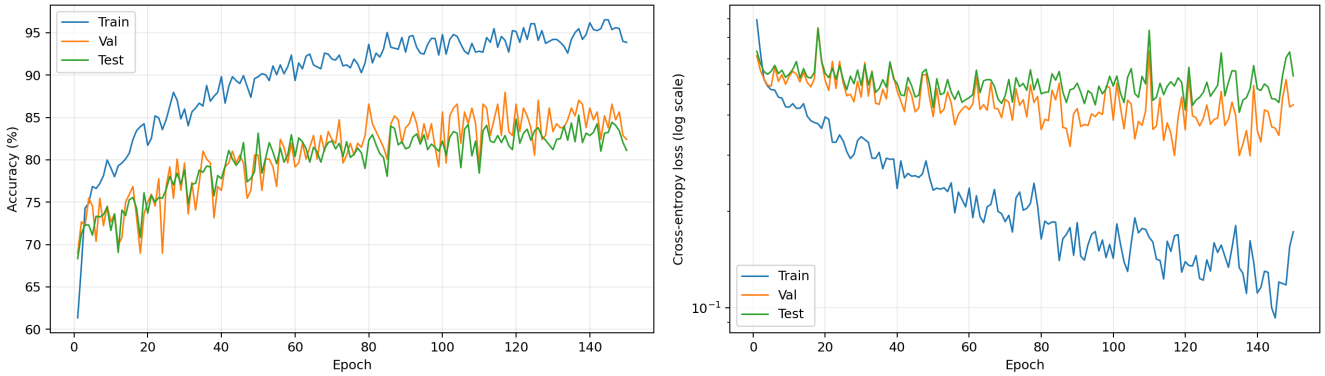


圖 5：左為 accuracy，右為 loss（對數軸）；Train／Val／Test 各 150 輪。

選定 epoch 117：train 94.10%、validation 87.96%、test 82.87%；選定 test loss 0.4934。最後一輪 train／validation accuracy 為 93.87%／82.41%。

E4 / ELU alpha=0.5

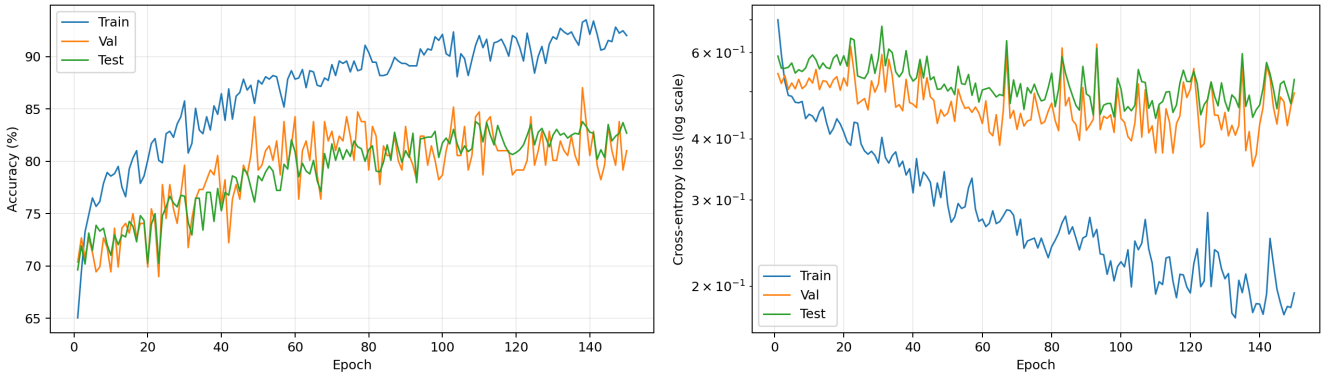


圖 6：左為 accuracy，右為 loss（對數軸）；Train／Val／Test 各 150 輪。

選定 epoch 138：train 93.29%、validation 87.04%、test 83.80%；選定 test loss 0.4428。最後一輪 train／validation accuracy 為 92.01%／81.02%。

Train 指標在 dropout 開啟且權重持續更新時累計；Val／Test 在每輪更新後以 eval 模式計算。曲線高度不能單憑 train 與 test 的大小判定資料洩漏或過擬合，應配合 validation loss 變化解讀。

2.7 訓練曲線：E5 與 E6

E5 / ELU alpha=2

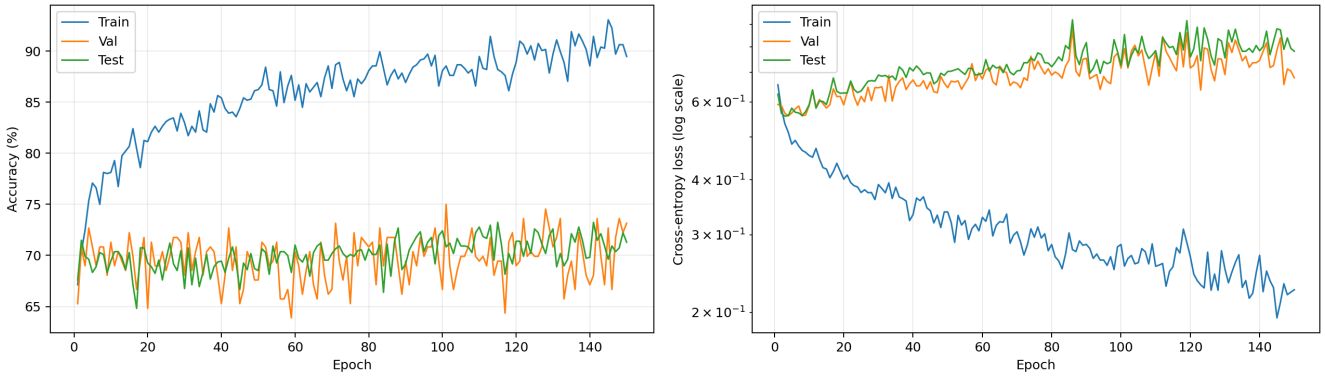


圖 7：左為 accuracy，右為 loss（對數軸）；Train／Val／Test 各 150 輪。

選定 epoch 101：train 88.54%、validation 75.00%、test 70.83%；選定 test loss 0.8534。最後一輪 train／validation accuracy 為 89.47%／73.15%。

E6 / Dropout=0

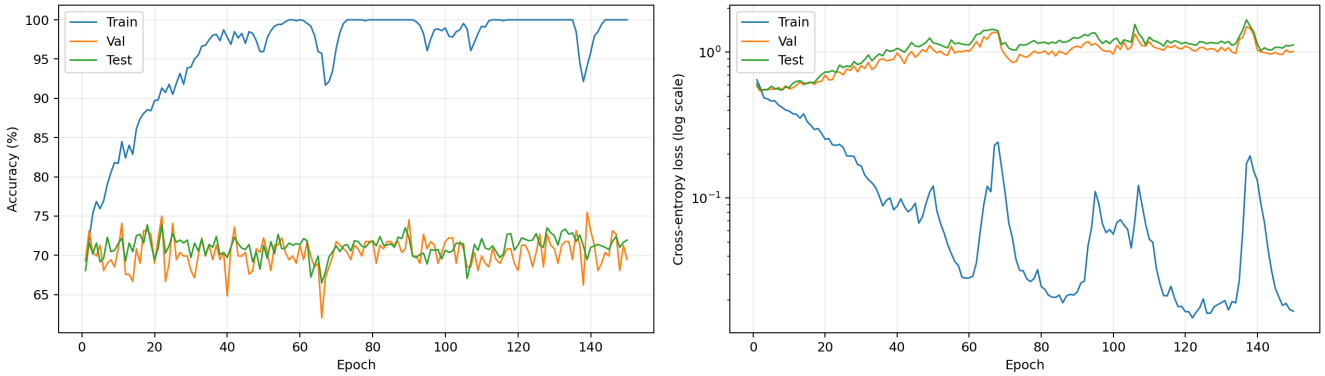


圖 8：左為 accuracy，右為 loss（對數軸）；Train／Val／Test 各 150 輪。

選定 epoch 139：train 94.10%、validation 75.46%、test 69.44%；選定 test loss 1.3816。最後一輪 train／validation accuracy 為 100.00%／69.44%。

Train 指標在 dropout 開啟且權重持續更新時累計；Val／Test 在每輪更新後以 eval 模式計算。曲線高度不能單憑 train 與 test 的大小判定資料洩漏或過擬合，應配合 validation loss 變化解讀。

2.8 訓練曲線：E7 與 E8

E7 / Dropout=0.5

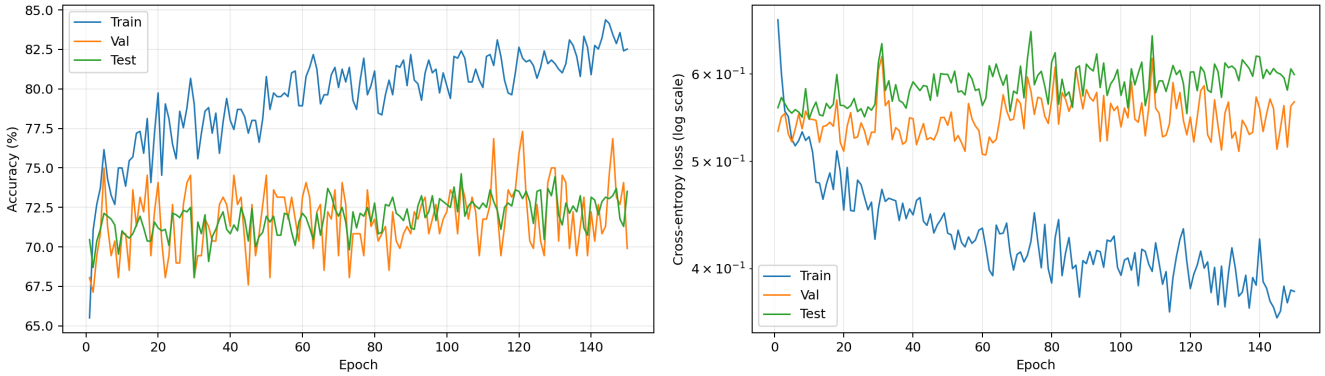


圖 9：左為 accuracy，右為 loss（對數軸）；Train／Val／Test 各 150 輪。

選定 epoch 121：train 81.94%、validation 77.31%、test 73.06%；選定 test loss 0.6027。最後一輪 train／validation accuracy 為 82.52%／69.91%。

E8 / DeepConvNet

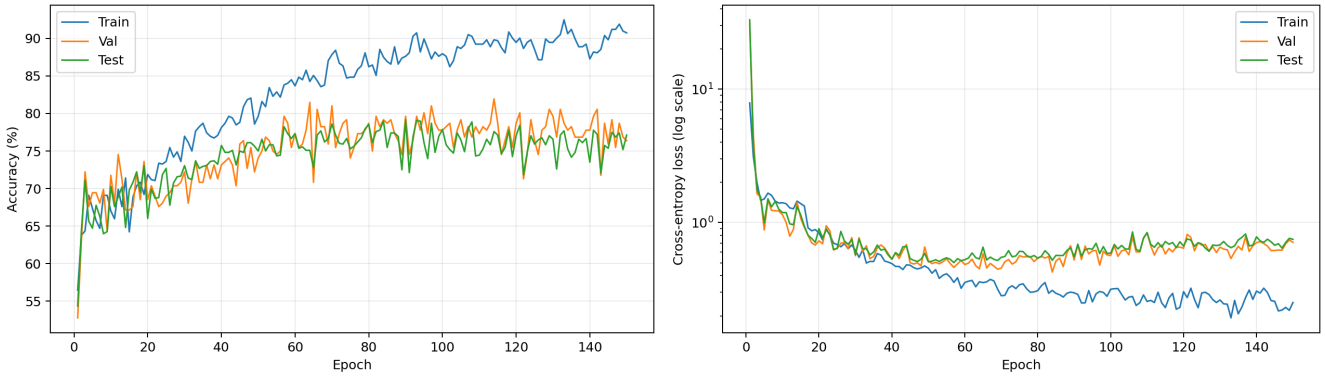


圖 10：左為 accuracy，右為 loss（對數軸）；Train／Val／Test 各 150 輪。

選定 epoch 114：train 89.81%、validation 81.94%、test 77.59%；選定 test loss 0.6555。最後一輪 train／validation accuracy 為 90.74%／76.39%。

Train 指標在 dropout 開啟且權重持續更新時累計；Val／Test 在每輪更新後以 eval 模式計算。曲線高度不能單憑 train 與 test 的大小判定資料洩漏或過擬合，應配合 validation loss 變化解讀。

3. Discussion

3.1 Activation、ELU 與 alpha

ELU 定義為：x > 0 時 f(x)=x；x <= 0 時 f(x)=alpha × (exp(x)-1)。正半軸保留線性梯度，負半軸連續下降並飽和至 -alpha [2]。負輸出可使 activation 的平均值更接近零；這不代表在本資料上必然勝過 ReLU。alpha 改變負半軸飽和值與斜率；只有 alpha=1 時左右導數在零點一致。

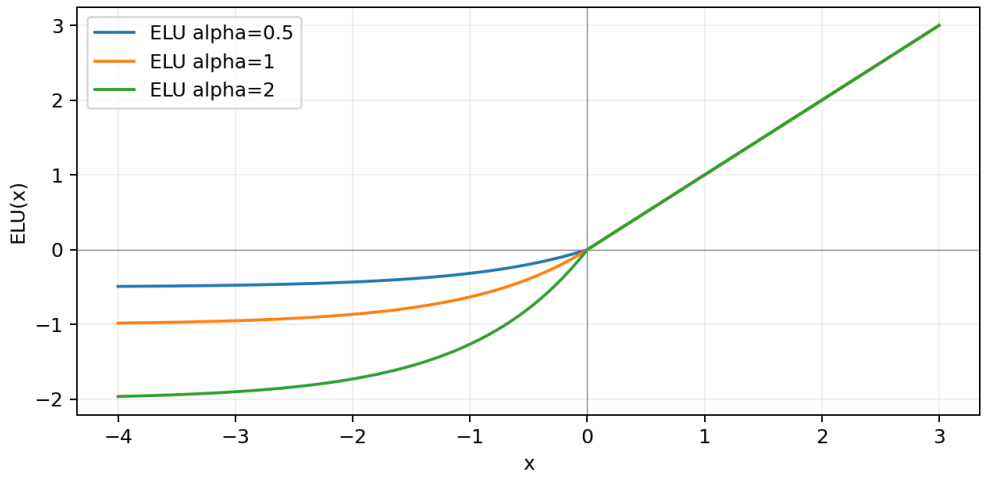


圖 11：本次比較的三種 ELU alpha。

基準 ELU 的選定 test accuracy 為 74.63%；ReLU 為 85.28%，LeakyReLU 為 82.87%。相對基準差異分別是 +10.65 與 +8.24 個百分點。LeakyReLU 在負半軸保留 0.01 的線性斜率；ReLU 則截為零。這次結果反映固定種子與指定學習率下的觀察，不代表普遍排序。

alpha=0.5／1／2 的選定 test accuracy 依序為 83.80%／74.63%／70.83%。alpha 改變訊號尺度與梯度分布，並與 BN、optimizer 互相作用；因此不能只靠函數圖形推論最終準確率，也不能將單次差異解讀為因果證明。

3.2 Dropout 與泛化

dropout=0／0.25／0.5 的選定 test accuracy 為 69.44%／74.63%／73.06%。較大 dropout 增加訓練噪聲與正則化，但也可能降低有效容量或使固定 150 輪仍未充分收斂。應同時查看 train loss 是否下降、validation loss 是否回升及選定輪次，不能單憑最高 train accuracy 判斷較好的設定。

具體而言，dropout=0 在第 150 輪的 train accuracy 已達 100.00%，但 validation accuracy 只有 69.44%；train loss 從 0.649 降到 0.017，validation loss 卻從 0.585 升至 1.012。這是本次最明顯的過擬合跡象；把訓練準確率推到 100% 並沒有改善保留資料表現。

3.3 Depthwise 與 separable convolution

一般卷積會同時混合輸入特徵圖並在 kernel 範圍內運算。Depthwise 將特徵圖分組，各組獨立學習；本作業空間層使用 in_channels=16、out_channels=32、groups=16，每個時間特徵獨立學習兩個跨 EEG 通道的空間濾波器。此處的 16 個輸入特徵圖，與原始兩個 EEG 電極通道是不同概念。

Separable convolution 先以 depthwise (1,15) 在每個特徵圖內擷取時間變化，再以 pointwise (1,1) 混合 32 個特徵圖。不含 bias，普通 32→32、(1,15) 卷積需要 32×32×15=15,360 個權重；分解後為 32×15+32×32=1,504，減少約 90.21%。這是該卷積模組的參數比較，並非整個模型的速度保證。

3.4 Bonus：DeepConvNet

DeepConvNet 使用時間卷積 (1,5) 後接跨通道 (2,1) 卷積，接續 25／50／100／200 filters 的 BN、ELU、MaxPool (1,2) 與 dropout=0.5。時間長度依序為 373、184、90、43，flatten 後為 8,600，最後線性輸出兩個 logits。依作業允許省略 max norm；其餘訓練規則與 EEGNet 相同。

模型	參數	選定 Val (%)	選定 Test (%)	執行分鐘
EEGNet 基準	4,018	80.09	74.63	0.16
DeepConvNet	150,977	81.94	77.59	0.22

DeepConvNet 參數量是 EEGNet 基準的 37.6 倍；選定 test accuracy 相差 +2.96 個百分點。較大容量並不自動保證較佳泛化，本次僅比較預先指定的共同 optimizer 設定，並未為各架構分別搜尋最佳學習率。執行時間包含訓練、評估與圖表輸出，也受 GPU 當時負載影響。

DeepConvNet 第一輪 test loss 為 33.02，而選定權重為 0.656；早期 loss 的大幅變動顯示共同學習率下的初始訓練並不穩定。loss 圖使用對數軸保留所有輪次，避免早期高值遮蔽後續趨勢。這支持下一步應透過 validation 比較較小學習率的假設，但本次未新增該實驗，不能斷言它一定有效。

3.5 限制與後續改進

每組僅執行 seed 42，沒有多種子平均、標準差或統計顯著性檢定。切分為相同受試者內的類別分層，不能宣稱能泛化到未見受試者。資料來源為課程提供的預處理 NPZ，本次沒有重新驗證原始訊號的試次生成方式。若後續延伸，應優先以多種子與跨受試者評估驗證穩定性，而不是根據已觀察的 test 曲線繼續調整設定。

4. GitHub Link 與重現資訊

GitHub Link：待填入自己的 repository URL。尚未發布，提交前必須補齊並確認助教可存取。

README 包含安裝、資料放置、完整八組實驗、單組實驗、checkpoint 評估與報告重新產生指令。requirements.txt 固定直接依賴，requirements-lock.txt 記錄實際完整環境。資料、虛擬環境與大型權重不隨一般 Git 提交。

產物對照

檔案	用途
results/comparison.csv	八組比較表的原始數值
results/<experiment>/history.csv	逐輪 train／validation／test 指標
results/<experiment>/config.json、split.npz	設定、資料校驗碼及固定切分
results/<experiment>/best.pt	Validation 選定 checkpoint
results/<experiment>/acc.png、loss.png	完整曲線
COMPLETION_CRITERIA.md	實際驗收結果與提交待辦

參考資料

[1] Lawhern et al. (2018). EEGNet: A Compact Convolutional Network for EEG-based Brain-Computer Interfaces. https://arxiv.org/abs/1611.08024

[2] Clevert, Unterthiner & Hochreiter (ICLR 2016). Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs). https://arxiv.org/abs/1511.07289

[3] Schirrmeister et al. Deep learning with convolutional neural networks for EEG decoding and visualization. Human Brain Mapping (2017), revised arXiv version 2018. https://arxiv.org/abs/1703.05051

[4] PyTorch 2.9 documentation: Conv2d, ELU, CrossEntropyLoss. https://docs.pytorch.org/docs/2.9/

[5] 課程提供：Lab2_EEGNET_spec.pdf、dataloader.py、main.py 與 EEGNet.py 骨架。作業要求以第 15-16 頁為主要報告依據。

提交前檢查

補齊學號、姓名與 GitHub URL，重新產生 PDF 並核對檔名 LAB2_學號_姓名.pdf；程式與 README 上傳自己的 GitHub，PDF 上傳 E3。已於 2026/10/19 核對 E3 作業頁，截止時間為 2026/11/05 23:59。此報告不表示已完成遠端發布或 E3 提交。