腦電訊號分類實驗報告

EEGNet 設定比較 多種子集成與 DeepConvNet 實作

學號 315553010　姓名 楊敦傑　課程 人工智慧醫學影像應用
實驗期間 2026 年 10 月 19 日至 10 月 28 日

摘要　本作業以 BCI Competition III IIIb 的兩通道 EEG 進行二元分類，自行實作 EEGNet 與 DeepConvNet。第一階段以八組固定設定比較激活函數、ELU α 與 dropout，驗證集選出的 ReLU 模型測試準確率為 85.28%。第二階段將搜尋與測試評估分開，完成 16 個候選的三種子比較，再以五個種子評估選定設定。驗證集選定權重的五模型 ensemble 達 87.78%；個別模型的平均為 84.72% ± 0.80%。事前指定的主要評估方法為全資料重訓 ensemble，其結果為 86.02%，仍未達 87%。本報告分別呈現上述結果，並分析模型容量、增強、訓練變異與評估限制。

1. Introduction

EEG 訊號具有時間變化與通道間的關聯。本實驗直接從兩個 EEG 通道、每筆 750 個取樣點學習分類特徵，輸入形狀為 (B, 1, 2, 750)，標籤由 1 / 2 轉為 0 / 1。模型輸出 (B, 2) logits，使用 CrossEntropyLoss 訓練，分類層不加入 softmax。Ensemble 才將各模型 logits 轉為機率後平均。

EEGNet 是 Lawhern 等人提出、專為腦機介面設計的精簡卷積網路 [1]。它依序以三個區塊取代手工特徵：第一層時間卷積相當於學習一組帶通濾波器；depthwise 卷積對每個時間濾波結果學習跨電極的空間權重，類似 common spatial pattern；separable 卷積再分別整理每個特徵的時間結構並混合特徵。這種設計以很少的參數涵蓋時間、頻率與空間資訊，適合樣本數有限的 EEG 資料。本作業先檢查其基本設計，再比較一般時間卷積與可重現的資料增強是否能改善驗證表現，同時用 DeepConvNet [3] 觀察較大模型的結果。

表 1　資料規模與用途

資料	原始筆數	本次用途
S4b_train + X11b_train	540 + 540	訓練 864 / 驗證 216
S4b_test + X11b_test	540 + 540	測試 1080
每個檔案的類別分布	270 / 270	兩類平衡

原訓練集與測試集各 1,080 筆，均包含 S4b 與 X11b 兩位受試者，兩類各占一半。固定以 seed 42 依「受試者 + 類別」分層，取 864 筆訓練、216 筆驗證；每一層分別為 216 / 54 筆。V2 的不同訓練種子共用此切分，測試集始終維持獨立。

2. Experiment Setups and Results

2.1 實驗設定與模型實作

EEGNet 架構

表 2　EEGNet 基準模型各層形狀

階段	運算	輸出形狀（不含 batch）
輸入	兩通道 EEG	1 × 2 × 750
時間特徵	Conv 1→16, (1,51), padding (0,25); BN	16 × 2 × 750
空間特徵	Conv 16→32, (2,1), groups=16; BN; activation	32 × 1 × 750
下採樣	AvgPool (1,4); Dropout	32 × 1 × 187
時間與特徵混合	Depthwise (1,15), groups=32; Pointwise (1,1); BN; activation	32 × 1 × 187
下採樣	AvgPool (1,8); Dropout	32 × 1 × 23
分類	Flatten 736; Linear 736→2	2 logits

基準模型的後段採 depthwise (1,15) 加 pointwise (1,1)，共 4,018 個可訓練參數。V2 的 full 選項將此後段改為 Conv2d(32,32,(1,15),padding=(0,7),bias=False)，不分組，也不另接 pointwise，總參數增為 17,874。其他空間卷積、池化與分類層維持相同，因此可直接比較後段卷積方式。

共同的訓練與評估規則

執行環境為 Python 3.12.14、PyTorch 2.9.1+cu126、CUDA 12.6、NumPy 2.2.6、Matplotlib 3.10.8，GPU 為 RTX 4070。固定隨機種子並開啟 deterministic 運算；每個實驗重新初始化模型與 optimizer，batch size 為 64。Loss 依各 batch 的樣本數加權平均，避免最後一個較小 batch 被過度加權。

NaN 由實際訓練資料的全域平均補值；864 筆訓練子集的補值平均為 −0.02532666。正規化候選只從訓練子集估計每通道 mean 與母體標準差，再套用至驗證與測試資料；全資料重訓則重新用全部訓練資料估計。

一般訓練優先保存 validation accuracy 較高的 checkpoint，同分取 validation loss 較低者，再同分保留較早輪次。權重以獨立複本保存，結束後重新載入並核對評估結果。全資料重訓沒有驗證集，僅保存事前固定輪數的最後權重。

V1 依作業要求逐輪記錄 train / validation / test 曲線，但八組設定在訓練前已固定。V2 改為只記錄 train / validation，所有設定與重訓輪數凍結後才統一評估 test。兩階段的測試資訊使用方式因此需分開解讀。

2.2 第一階段固定設定比較

V1 八組皆使用 seed 42、150 epochs、Adam、learning rate 0.01、weight decay 0.001。EEGNet 基準為 ELU α=1、dropout=0.25；activation、α 與 dropout 各組只改變指定變因，DeepConvNet 使用 ELU α=1、dropout=0.5。

表 3　V1 八組結果與描述性的測試峰值

設定	選定輪次	Val (%)	選定 Test (%)	Test 峰值 (%)
E1 EEGNet baseline	128	80.09	74.63	76.57
E2 ReLU	139	89.81	85.28	85.28
E3 LeakyReLU	117	87.96	82.87	85.28
E4 ELU alpha=0.5	138	87.04	83.80	83.80
E5 ELU alpha=2	101	75.00	70.83	73.24
E6 Dropout=0	139	75.46	69.44	73.89
E7 Dropout=0.5	121	77.31	73.06	74.63
E8 DeepConvNet	114	81.94	77.59	79.17

依 validation 選出的設定是 ReLU，第 139 輪 validation accuracy 為 89.81%，對應 test accuracy 為 85.28%。表中的 test 峰值僅描述已記錄的曲線，不能用來選權重或當作未經挑選的泛化估計。八組完整曲線置於附錄。

表 4　V1 ReLU 的原始數值證據

指標	逐輪最高測試成績代表	驗證集選定 checkpoint
設定	eegnet_relu	eegnet_relu
Epoch	137	139
Train accuracy (%)	94.6759	96.1806
Validation accuracy (%)	87.9630	89.8148
Test accuracy (%)	85.2778	85.2778
Train loss	0.12328002	0.10839006
Validation loss	0.26556925	0.30276698
Test loss	0.42118062	0.41139699

上表直接取自 history.csv；accuracy 單位為百分比，loss 為依樣本數加權的交叉熵。第 137 輪是首次出現測試峰值的代表輪次，實際保存的仍是驗證集選定的第 139 輪。V1 尚未達 87%，因此後續以明確分離驗證搜尋與測試報告的 V2 流程進一步比較。

2.3 第二階段驗證集搜尋

V2 以 ReLU、dropout=0.25 為起點，依序比較卷積方式、weight decay、learning rate 與 scheduler、正規化、增強、dropout、activation、optimizer 及訓練上限。每個候選使用 seeds 42 / 43 / 44；依三個 validation-selected checkpoint 的平均 validation accuracy 選設定，同分比較平均 validation loss。相同設定重用既有結果，共形成 16 個不同候選。

表 5　依序搜尋的候選設定

代號	延續設定	此次變更	訓練上限
c00	起點	ReLU 基準	150
c01	c00	full 卷積	150
c02	c01	weight decay 0	150
c03	c01	weight decay 0.0001	150
c04	c01	cosine scheduler	150
c05	c01	lr 0.001	150
c06	c01	lr 0.001 + cosine	150
c07	c01	per-channel z-score	150
c08	c01	訓練資料增強	150
c09	c08	dropout 0.1	150
c10	c08	dropout 0.5	150
c11	c08	LeakyReLU 0.01	150
c12	c08	ELU α=0.5	150
c13	c08	ELU α=1	150
c14	c08	AdamW	150
c15	c08	300 epochs	300

除列出的變更外，候選承接「延續設定」的全部參數。c00 為 depthwise、Adam、lr 0.01、weight decay 0.001、scheduler none、無正規化、無增強；其餘未變更的參數依此遞延。增強使用獨立且固定種子的 generator，依序對每筆做 ±50 點 circular time shift、0.9–1.1 倍振幅縮放與 Gaussian noise；噪聲 σ 為原 trial / channel 時間標準差的 0.05 倍。

最後選出 c15：full、ReLU、dropout=0.25、Adam、lr 0.01、weight decay 0.001、無 scheduler、無正規化、啟用增強，上限 300 epochs。再補 seeds 45 / 46，不據此重選設定。五個最佳輪次為 243、49、70、214、78，中位數 78 用於全資料重訓。

2.4 第二階段設定比較結果

下表一律使用相同三個訓練種子，± 為樣本標準差（ddof=1）。Δ 是相對上一頁「延續設定」的變化，單位為百分點。Test 數值於搜尋、五 seed 設定與全資料重訓輪數全部凍結後才補列，不參與任何選擇。

表 6　三種子 ablation 結果

代號	Validation %	Test %	Δ Val	Δ Test
c00	87.65 ± 2.33	83.18 ± 1.82	+0.00	+0.00
c01	89.04 ± 1.41	83.58 ± 1.02	+1.39	+0.40
c02	85.34 ± 3.08	80.96 ± 1.49	-3.70	-2.62
c03	85.19 ± 3.24	82.35 ± 2.47	-3.86	-1.23
c04	86.88 ± 2.28	83.15 ± 1.07	-2.16	-0.43
c05	87.19 ± 1.34	82.65 ± 0.57	-1.85	-0.93
c06	85.49 ± 2.28	83.12 ± 1.74	-3.55	-0.46
c07	87.19 ± 1.63	82.62 ± 1.80	-1.85	-0.96
c08	89.66 ± 1.17	83.77 ± 1.36	+0.62	+0.19
c09	88.73 ± 0.71	83.89 ± 0.72	-0.93	+0.12
c10	89.51 ± 1.49	83.64 ± 0.46	-0.15	-0.12
c11	88.89 ± 1.22	86.05 ± 0.79	-0.77	+2.28
c12	89.66 ± 0.27	81.94 ± 0.76	+0.00	-1.82
c13	82.72 ± 4.68	76.42 ± 4.34	-6.94	-7.35
c14	88.89 ± 1.22	83.98 ± 2.89	-0.77	+0.22
c15	89.66 ± 1.17	84.63 ± 0.56	+0.00	+0.86

full 卷積使平均 validation accuracy 由 87.65% 提升至 89.04%；再加入增強後為 89.66%。300 epochs 與 150 epochs 的平均 validation accuracy 相同，c15 是依較低 validation loss 勝出，不能解讀為準確率再提高。

ELU α=0.5 的平均 validation accuracy 也與 ReLU 相同，但其平均 validation loss 較高，因此未獲選。LeakyReLU 在最後補列的 test 平均較高，也沒有被事後改選。這保留了以 validation 選模、test 僅作報告的界線。

這些對照依序承接前一步選定設定，是貪婪搜尋而非完整因子實驗。表中的差值描述各步驟的條件性結果，不能視為各項改動互相獨立的因果效應，也沒有排除超參數間的交互作用。

2.5 五種子最終評估

表 7　事前固定的四種報告方法

方法	Test accuracy %	權重與組合規則
864 筆訓練 個別模型	84.7222 ± 0.8045	各 seed 依 validation 選權重
864 筆訓練 Ensemble	87.7778	五模型 softmax 等權平均
1,080 筆重訓 個別模型	82.9630 ± 1.9278	固定 78 輪 取最後權重
1,080 筆重訓 Ensemble	86.0185	事前指定主要成果 等權平均

表 8　五個種子的選定輪次與測試結果

Seed	選定 epoch	Val %	選定 Test %	重訓 Test %
42	243	88.4259	84.9074	82.5926
43	49	89.8148	85.0000	84.8148
44	70	90.7407	83.9815	84.3519
45	214	88.4259	85.8333	79.9074
46	78	89.3519	83.8889	83.1481

Validation-selected ensemble 達到 87.7778%，較 V1 ReLU 的 85.2778% 高 2.50 個百分點，但同時改變了模型與集成方式，不能把差距全歸因於 full 卷積。事前指定的主要成果為全資料 ensemble，其 86.0185% 未達門檻；不以較高結果事後替換主要成果。

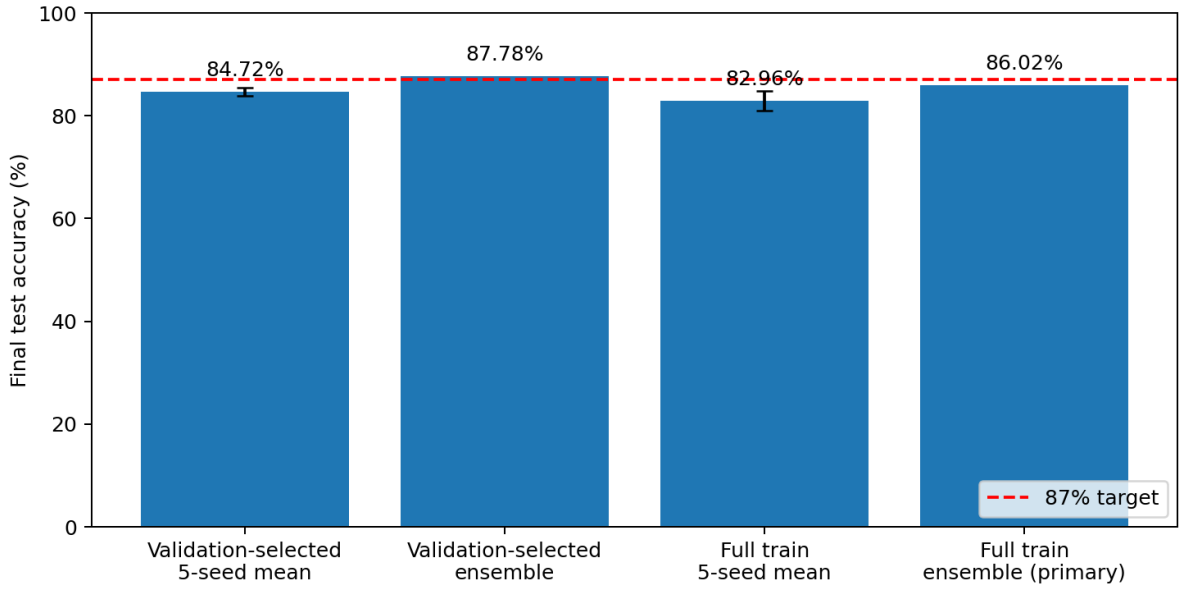


圖 1　最終測試準確率。個別模型柱的誤差棒是五次訓練的樣本標準差；ensemble 為單一組合結果。

2.6 Highest Testing Accuracy (Screenshot)

下圖為重新載入五個凍結 checkpoint 後，執行 show_final_v2.py 的 PowerShell 輸出截圖。本次最高 testing accuracy 為 validation-selected 五模型 softmax ensemble 的 87.7778%（標示為黃色）；同一畫面也列出各 seed 的單模型結果，以及事前指定為主要成果的全資料重訓 ensemble 86.0185%。截圖中的數值與表 7、final_summary.json 一致。

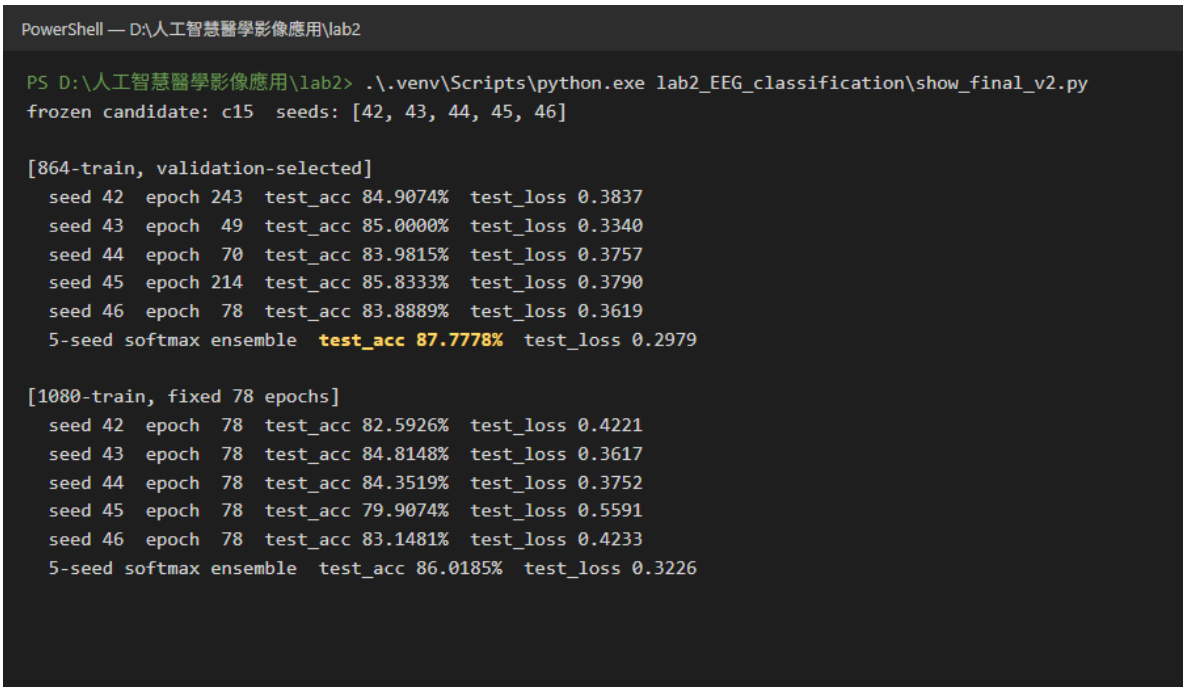


圖 2　最高 testing accuracy 的執行輸出截圖（validation-selected 5-seed ensemble：87.7778%）。

2.7 第二階段代表訓練曲線

以下固定展示第一個搜尋種子 42、第一個新增種子 45，以及全資料重訓的種子 42，並非依 test 表現挑圖。每組左圖為 accuracy，右圖為 loss（對數軸）；其餘曲線皆保存在 results_v2 各 seed 目錄。

c15 seed 42，validation 選定第 243 輪

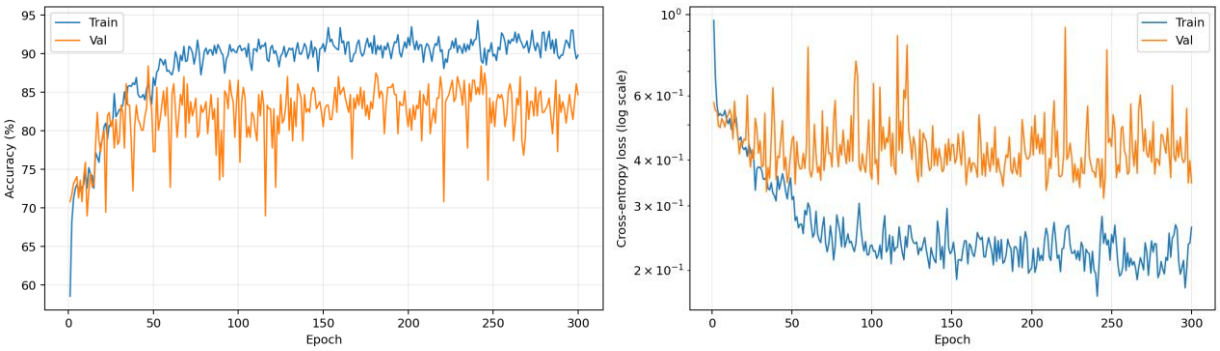


圖 3　c15 seed 42，validation 選定第 243 輪。V2 未逐輪計算 test；全資料訓練也沒有 validation 曲線。

c15 seed 45，validation 選定第 214 輪

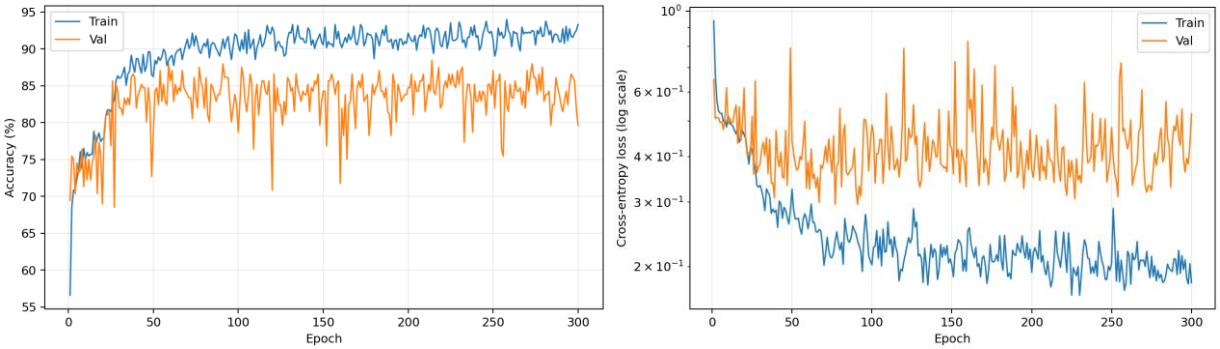


圖 4　c15 seed 45，validation 選定第 214 輪。V2 未逐輪計算 test；全資料訓練也沒有 validation 曲線。

全資料 seed 42，固定訓練 78 輪

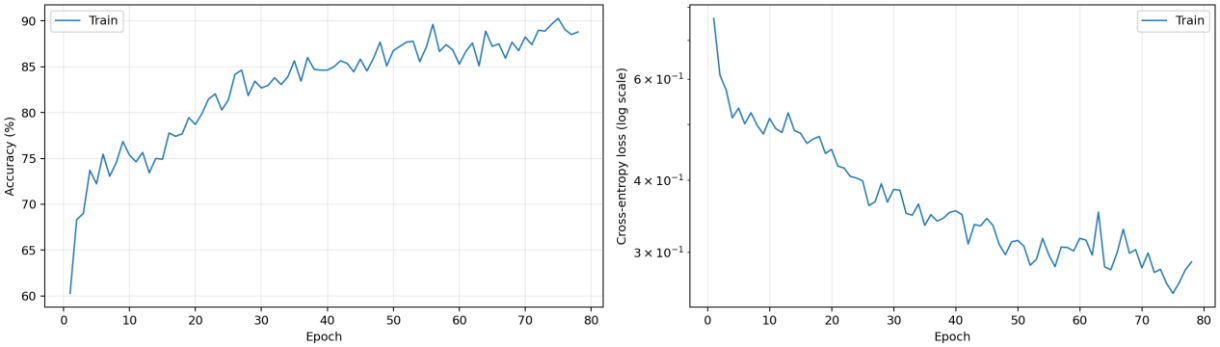


圖 5　全資料 seed 42，固定訓練 78 輪。V2 未逐輪計算 test；全資料訓練也沒有 validation 曲線。

3. Discussion

3.1 模型實作方式

模型寫在 models/EEGNet.py，以 PyTorch nn.Sequential 自行組合，沒有使用預訓練權重。EEGNet 分為四個區塊：firstconv 為 Conv2d(1,16,(1,51),padding=(0,25)) 加 BatchNorm；depthwiseConv 為 Conv2d(16,32,(2,1),groups=16) 加 BatchNorm、activation、AvgPool(1,4) 與 dropout；separableConv 依 --separable 選項建立 depthwise (1,15) + pointwise (1,1)，或投影片式的一般 Conv2d(32,32,(1,15))，再接 BatchNorm、activation、AvgPool(1,8) 與 dropout；classify 將 32×23 特徵攤平後接 Linear(736,2)。activation_layer 依參數回傳 ELU(α)、ReLU 或 LeakyReLU，使同一份程式能比較各種設定。main.py 負責資料切分、補值、訓練迴圈、checkpoint 選擇與曲線繪製，experiments_v2.py 則依 protocol 執行搜尋與最終評估。

3.2 激活函數與 ELU 的作用

ELU 的正半軸為線性，負半軸隨 x 下降而飽和至 −α [2]，其定義如下。

$$ELU(x) = \begin{cases} x & x > 0 \\ \alpha\,(e^{x} - 1) & x \le 0 \end{cases}$$

α 改變負半軸的飽和值與斜率；α=1 時，左右導數在原點一致。允許負輸出可能使 activation 平均值更接近零，但不能單憑這個性質保證分類較準。ReLU 的負半軸為零；LeakyReLU 則保留 0.01 的斜率，三者會產生不同的特徵與梯度分布。

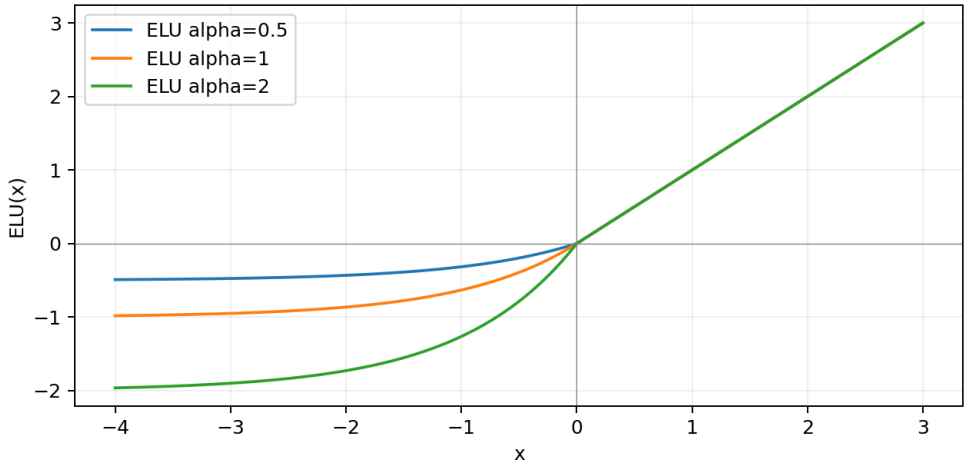


圖 6　ELU α=0.5、1、2 的函數曲線。

V1 中 ELU α=0.5 / 1 / 2 的選定 test accuracy 分別為 83.80% / 74.63% / 70.83%；ReLU 為 85.28%，LeakyReLU 為 82.87%。這反映特定模型、超參數與 seed 下的差異。V2 換成 full 卷積並加入增強後，仍由 validation 選出 ReLU，但各組間距已不同，因此激活函數的效果需連同整個訓練設定解讀。

3.3 Dropout 與過擬合

V1 dropout=0 / 0.25 / 0.5 的選定 test accuracy 分別為 69.44% / 74.63% / 73.06%。其中無 dropout 在第 150 輪的 train accuracy 已達 100%，validation accuracy 卻只有 69.44%，是訓練記憶未轉移到保留資料的明顯例子。V2 以三 seeds 比較後保留 0.25；提高到 0.5 並未得到較佳 validation 結果。

3.4 Depthwise Convolution 與 Separable Convolution

Depthwise convolution 讓每個輸入通道各自使用獨立的卷積核（PyTorch 以 groups=in_channels 實作），不同通道之間不互相混合，因此參數量只與通道數成正比。Separable convolution（depthwise separable）則把一般卷積拆成兩步：先做 depthwise 卷積處理每個通道內的時間或空間結構，再用 1×1 pointwise 卷積混合通道。對 C_in→C_out、核長 K 的卷積，一般卷積需 C_in×C_out×K 個權重，separable 只需 C_in×K + C_in×C_out。

空間 depthwise 層使用 in_channels=16、out_channels=32、groups=16，對每個時間特徵學習兩個跨 EEG 電極的濾波器。這裡的 16 個輸入特徵通道與原始兩個 EEG 電極通道不同。後段 depthwise + pointwise 則先逐特徵做時間濾波，再混合特徵。

表 9　兩種後段卷積的參數量

設計	後段卷積權重	全模型參數
Depthwise + pointwise	32×15 + 32×32 = 1,504	4,018
Full 一般卷積	32×32×15 = 15,360	17,874

一般卷積能為每一對輸入與輸出特徵學習獨立的時間濾波器，限制較少，模型參數約為基準的 4.45 倍。初始三 seed 對照的 validation 平均增加 1.39 個百分點，最終 test 平均增加 0.40 個百分點，支持它在本設定下有改善。不過容量增加也可能提高過擬合風險；full 是一般卷積，並非嚴格意義的 separable convolution。

3.5 資料增強與訓練上限

加入增強後，三 seed validation 平均增加 0.62 個百分點，最後補列的 test 平均增加 0.19 個百分點。位移使模型接觸不同的時間對齊，縮放與噪聲增加訊號擾動，可能減少對特定波形細節的依賴。三項增強同時啟用，因此無法分辨單項貢獻。正規化、較低 weight decay、較低 lr、cosine 與 AdamW 未在本搜尋路徑獲選，不能推論它們普遍無效。

將訓練上限拉長至 300 輪，提供了更多 validation checkpoint 的候選，但沒有提高三 seed 平均 validation accuracy；它僅以較低 validation loss 勝出。較多輪次也增加反覆比較同一驗證集的次數，因此應保留 validation 過度擬合的可能。

3.6 Ensemble 與全資料重訓

Ensemble 對五個模型的 softmax 等權平均，可降低部分初始化、shuffle、dropout 與增強隨機性造成的差異。本次 validation-selected 個別模型平均為 84.72%，ensemble 為 87.78%；五個模型共享訓練資料，誤差並非獨立，不能假設集成一定改善。

全資料重訓的單模型平均降為 82.96%，ensemble 為 86.02%。78 輪雖由 validation 最佳輪次的中位數決定，仍不保證原切分的訓練節奏能直接轉移到 1,080 筆資料。增加訓練資料與改變停止輪數同時發生，無法據此判定更多資料有害。

3.7 評估限制

五個 seeds 共用同一個 864 / 216 切分，± 標準差只反映訓練隨機性，不是信賴區間，也不包含資料重新切分的不確定性。目前是相同受試者內的分層評估，不能推論未見受試者的泛化能力。資料來自課程提供的預處理 NPZ，本次沒有重新驗證原始訊號試次的形成方式。

V1 的 test 結果已在先前實驗中被查看，因此 V2 不能宣稱是完全未曾接觸的全新盲測。本次額外搜尋仍以 validation 為唯一選擇依據；設定、五個 seeds、78 輪重訓與等權 ensemble 規則都先凍結，最後才統一計算 test，未依新的測試結果追加調參。後續若要評估穩健性，應先訂定新的交叉驗證或跨受試者流程。

3.8 結論

本作業完成兩種網路與可重現訓練流程。V2 的 full 卷積與增強在固定驗證流程下獲選，五模型 validation-selected ensemble 達 87.78%，達成指定門檻；單模型平均與事前指定的全資料 ensemble 分別為 84.72% 與 86.02%。這表示此次改善主要應以完整集成方法描述，仍需更廣的資料切分驗證其穩定性。

4. GitHub Link

https://github.com/Fergus4506/LAB2_EEGNet_MedicalImaging.git

README 提供環境安裝、資料位置、V1 歷史實驗與 V2 搜尋 / 最終評估指令。V2 搜尋與 final 階段分開執行，既有目錄拒絕覆寫；所有新成果保存於 results_v2，原 results 的檔案雜湊確認未變。原始資料、虛擬環境與大型權重不隨一般 Git 提交。

表 10　V2 重現與驗收資料

檔案	用途
config.json 與 split.npz	參數、前處理統計量、環境與資料切分
history.csv 與 best.pt	逐輪 train / validation 紀錄與選定權重
summary.json 與 evaluation.json	重載驗證、選擇規則與最後 test 結果
comparison.csv 與 ablation CSV	55 次訓練與各階段三 seed 比較
protocol.json 與 frozen_selection.json	test 前固定的搜尋流程與最終設定
final_summary.json	五 seed 平均、標準差與兩種 ensemble

V2 共完成 16 個候選、55 次訓練、8,640 epochs。selfcheck 與成果稽核通過，涵蓋輸入形狀、梯度、加權 loss、增強可重現性、train-only 統計量、切分一致性、checkpoint 重載、固定輪數與防覆寫。

5. Bonus: DeepConvNet

DeepConvNet 先以 (1,5) 時間卷積與 (2,1) 跨通道卷積處理訊號，後續使用 25 / 50 / 100 / 200 filters，每段接 BN、ELU、MaxPool (1,2) 與 dropout=0.5。池化後時間長度依序為 373、184、90、43，flatten 為 8,600，最後輸出兩個 logits；依作業允許省略 max norm。

表 11　V1 相同訓練規則下的兩模型比較

模型	參數	選定 Val (%)	選定 Test (%)	執行分鐘
EEGNet 基準	4,018	80.09	74.63	0.16
DeepConvNet	150,977	81.94	77.59	0.22

DeepConvNet 有 150,977 個參數，validation 選定模型的 test accuracy 為 77.59%，高於 ELU EEGNet 基準的 74.63%，但低於 ReLU EEGNet 的 85.28%。它只做了 V1 單一 seed 比較，沒有另做 V2 式的超參數搜尋，不能用本結果判定架構優劣。初期 test loss 曾達 33.02，選定權重為 0.656，顯示訓練早期較不穩定；loss 曲線以對數軸保留這段變化。

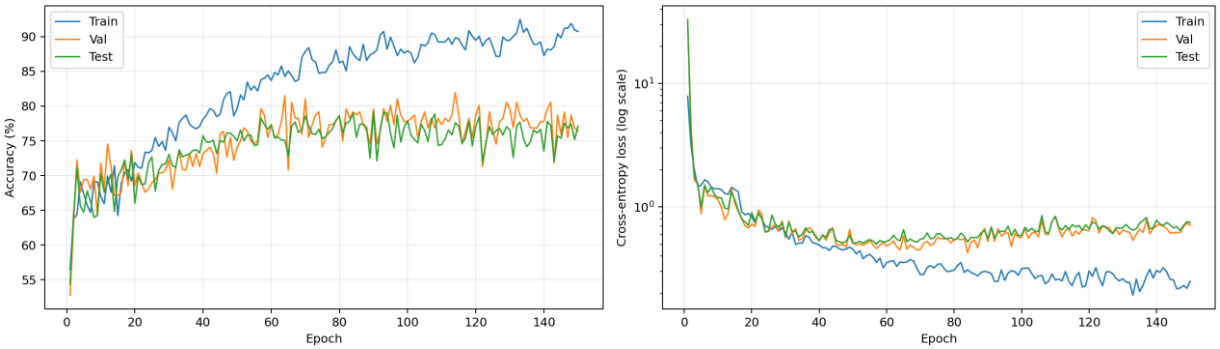


圖 7　DeepConvNet 的 train / validation / test 曲線。選定第 114 輪，test accuracy 77.59%。

參考資料

[1] Lawhern et al. (2018). EEGNet: A Compact Convolutional Network for EEG-based Brain-Computer Interfaces. https://arxiv.org/abs/1611.08024

[2] Clevert, Unterthiner & Hochreiter (ICLR 2016). Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs). https://arxiv.org/abs/1511.07289

[3] Schirrmeister et al. Deep learning with convolutional neural networks for EEG decoding and visualization. Human Brain Mapping (2017), revised arXiv version 2018. https://arxiv.org/abs/1703.05051

[4] PyTorch 2.9 documentation: Conv2d, ELU, CrossEntropyLoss. https://docs.pytorch.org/docs/2.9/

[5] 課程提供：Lab2_EEGNET_spec.pdf、dataloader.py、main.py 與 EEGNet.py 骨架。作業要求以第 15-16 頁為主要報告依據。

附錄 第一階段完整訓練曲線

V1 固定設定下的 150 輪 train / validation / test 紀錄。左為 accuracy，右為 loss（對數軸）；test 曲線僅供作業呈現，權重仍依 validation 選擇。

EEGNet ELU 基準

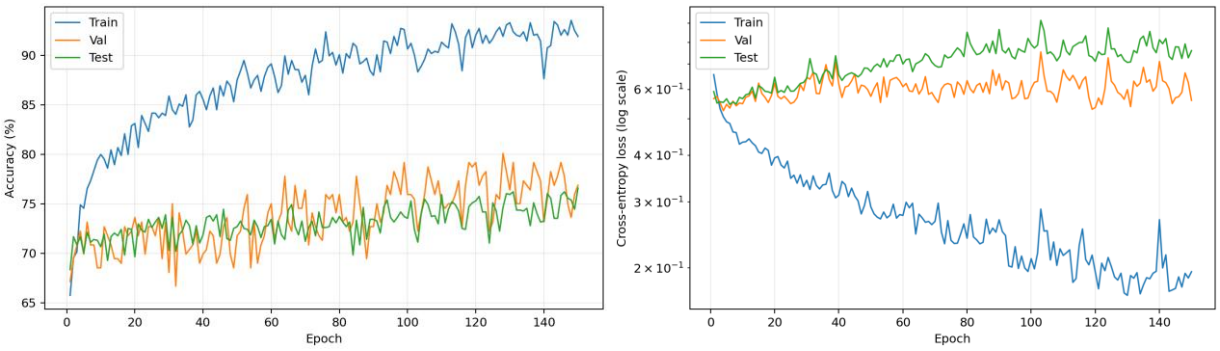


圖 8　EEGNet ELU 基準 的完整訓練與評估曲線。

選定第 128 輪，validation 80.09%，test 74.63%，test loss 0.7431。

ReLU

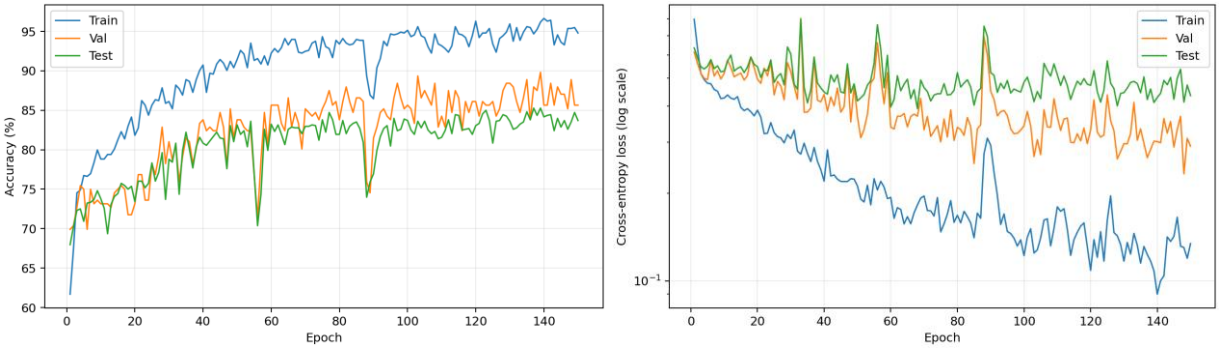


圖 9　ReLU 的完整訓練與評估曲線。

選定第 139 輪，validation 89.81%，test 85.28%，test loss 0.4114。

Train 指標是在 dropout 啟用及權重更新過程中累計，validation / test 則在各輪結束後以 eval 模式計算。因此三條曲線的高度不能直接當作資料洩漏與否的證據，需連同 loss 與選模規則判讀。

附錄 第一階段完整訓練曲線續

V1 固定設定下的 150 輪 train / validation / test 紀錄。左為 accuracy，右為 loss（對數軸）；test 曲線僅供作業呈現，權重仍依 validation 選擇。

LeakyReLU

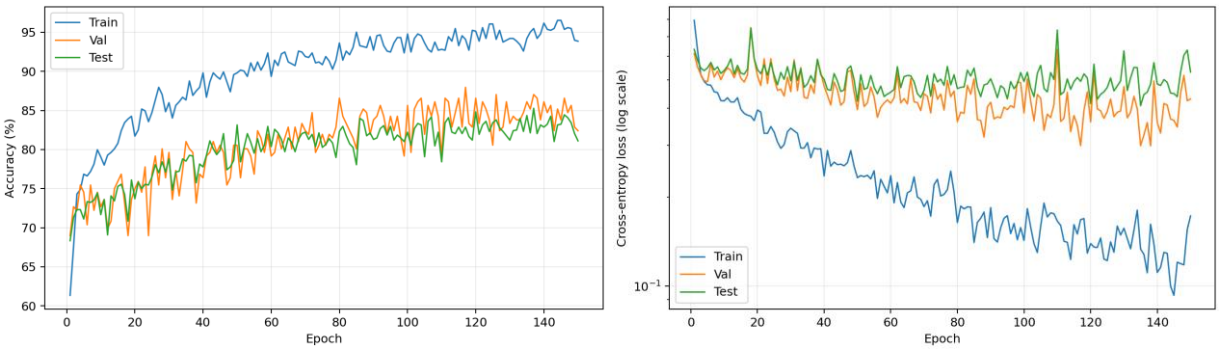


圖 10　LeakyReLU 的完整訓練與評估曲線。

選定第 117 輪，validation 87.96%，test 82.87%，test loss 0.4934。

ELU α=0.5

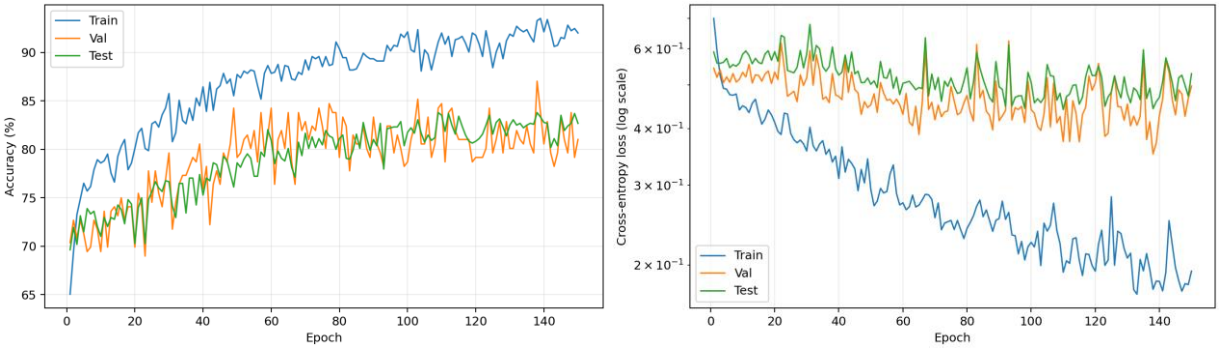


圖 11　ELU α=0.5 的完整訓練與評估曲線。

選定第 138 輪，validation 87.04%，test 83.80%，test loss 0.4428。

Train 指標是在 dropout 啟用及權重更新過程中累計，validation / test 則在各輪結束後以 eval 模式計算。因此三條曲線的高度不能直接當作資料洩漏與否的證據，需連同 loss 與選模規則判讀。

附錄 第一階段完整訓練曲線續

V1 固定設定下的 150 輪 train / validation / test 紀錄。左為 accuracy，右為 loss（對數軸）；test 曲線僅供作業呈現，權重仍依 validation 選擇。

ELU α=2

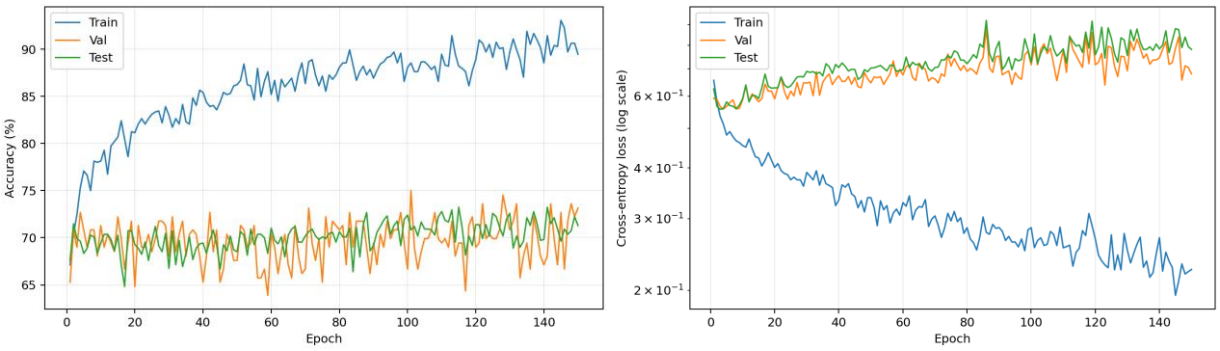


圖 12　ELU α=2 的完整訓練與評估曲線。

選定第 101 輪，validation 75.00%，test 70.83%，test loss 0.8534。

Dropout=0

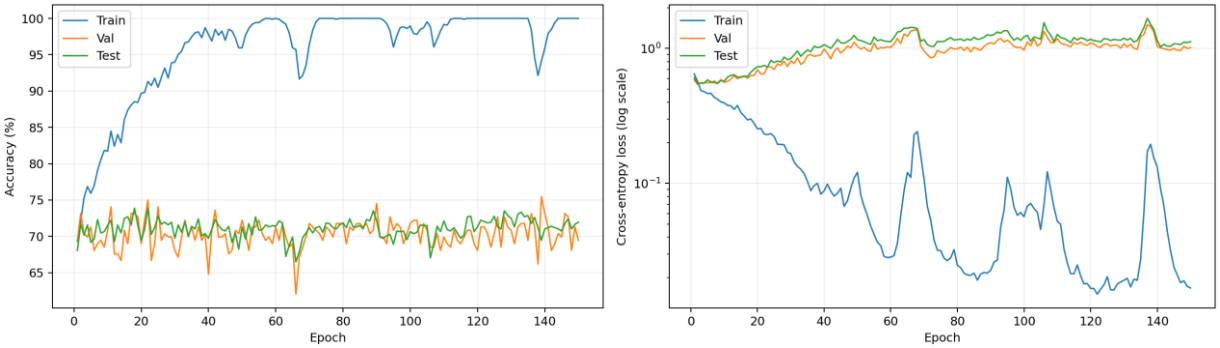


圖 13　Dropout=0 的完整訓練與評估曲線。

選定第 139 輪，validation 75.46%，test 69.44%，test loss 1.3816。

Train 指標是在 dropout 啟用及權重更新過程中累計，validation / test 則在各輪結束後以 eval 模式計算。因此三條曲線的高度不能直接當作資料洩漏與否的證據，需連同 loss 與選模規則判讀。

附錄 第一階段完整訓練曲線續

V1 固定設定下的 150 輪 train / validation / test 紀錄。左為 accuracy，右為 loss（對數軸）；test 曲線僅供作業呈現，權重仍依 validation 選擇。

Dropout=0.5

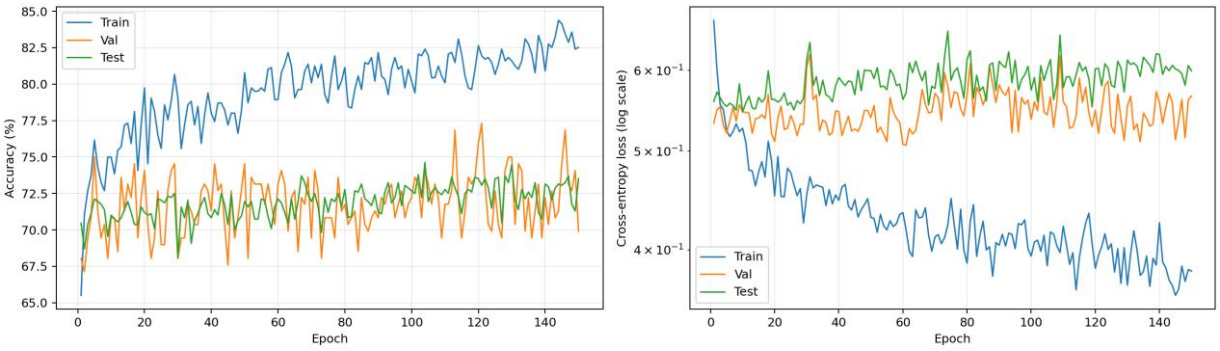


圖 14　Dropout=0.5 的完整訓練與評估曲線。

選定第 121 輪，validation 77.31%，test 73.06%，test loss 0.6027。

DeepConvNet

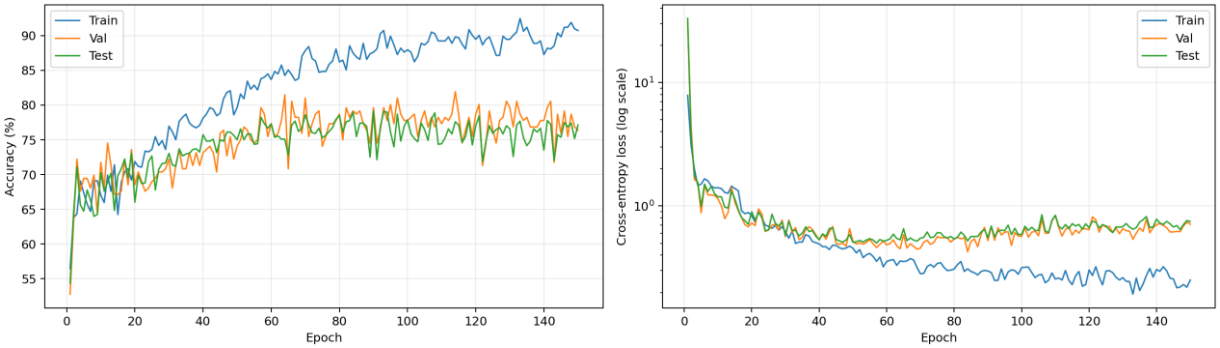


圖 15　DeepConvNet 的完整訓練與評估曲線。

選定第 114 輪，validation 81.94%，test 77.59%，test loss 0.6555。

Train 指標是在 dropout 啟用及權重更新過程中累計，validation / test 則在各輪結束後以 eval 模式計算。因此三條曲線的高度不能直接當作資料洩漏與否的證據，需連同 loss 與選模規則判讀。